Universidad Nacional de Colombia
Maestría en Geomática
Percepción Remota Avanzada (2026-2), Informe 1
Lina María Quintero Fonseca

repositorio https://github.com/linaq11/cgsm-alphaearth-vs-espectral

Representaciones de modelos fundacionales frente a variables espectrales para la clasificación de coberturas asociadas al manglar en la Ciénaga Grande de Santa Marta: una comparación con validación espacial

Resumen

Las representaciones preentrenadas de modelos fundacionales geoespaciales se han propuesto como alternativa a las variables espectrales, pero evaluar su aporte exige controlar la autocorrelación espacial y usar una línea base temporalmente comparable. Se compararon siete configuraciones de entrada sobre 600 puntos de la Ciénaga Grande de Santa Marta, cinco variantes espectrales de Sentinel-2, AlphaEarth 2021 y su combinación, con el mismo Random Forest y cuatro esquemas de evaluación espacial. Frente a una línea base espectral multitemporal de 2021, AlphaEarth mejoró el macro-F1 en 0,038 con bloques de 6 km, y desapareció con bloques de 16 km. El régimen de 16 km original, con exclusión de 8 km, dejó a cada pliegue con menos de la mitad del entrenamiento y casi sin alguna clase; al corregir la exclusión a 3 km, justificada por el variograma de los residuos, y promediar diez posiciones de la malla, ni AlphaEarth ni la combinación superaron a la línea base a esa separación. La ventaja también disminuyó al redistribuir los bloques en diez pliegues, un patrón compatible con eficiencia de etiquetas, aunque esa redistribución también cambió la composición del entrenamiento. La combinación de AlphaEarth con las variables espectrales fue la mejor configuración a 6 km, con una mejora significativa (permutación por bloques, p = 0,0001); a 16 km con el régimen corregido no superó a la línea base de forma consistente. Los resultados se mantuvieron al excluir las etiquetas en conflicto con otros productos cartográficos. En conjunto, los resultados muestran que el aporte predictivo de AlphaEarth depende del régimen de validación espacial y que la combinación de ambas fuentes presenta el desempeño más consistente en los regímenes por bloques, con ESA WorldCover 2021 como referencia temática.

Introducción

Los manglares son reconocidos por concentrar grandes reservas de carbono y por desempeñar funciones de protección costera desproporcionadas frente a su extensión (Donato et al., 2011; Giri et al., 2011). Su seguimiento mediante sensores remotos requiere distinguir el bosque de coberturas vecinas con firmas espectrales semejantes, en particular los humedales herbáceos y los cuerpos de agua someros. En Colombia se ha documentado una disminución gradual de la extensión del manglar entre 1984 y 2020 (Murillo-Sandoval et al., 2022). En la Ciénaga Grande de Santa Marta, parte de esta pérdida se ha relacionado con episodios de hipersalinidad asociados a la alteración de los aportes de agua dulce, situación que ha motivado distintas acciones de rehabilitación desde la década de 1990 (Botero y Salzwedel, 1999; Rivera-Monroy et al., 2006; Jaramillo et al., 2018).

La clasificación supervisada de estas coberturas se ha abordado tradicionalmente mediante clasificadores de conjunto y variables espectrales construidas de manera explícita, entre ellas reflectancias e índices normalizados. Random Forest se utiliza ampliamente en percepción remota por su estabilidad frente a variables redundantes y por su bajo costo de ajuste (Breiman, 2001; Belgiu y Drăguţ,

2016). En la CGSM, Vinasco et al. (2020) aplicaron clasificación automática para detectar cambios de cobertura y, posteriormente, Montes-Chaura et al. (2026) combinaron PlanetScope, Sentinel-1 y Sentinel-2 para analizar cambios de uso y cobertura entre 2016 y 2024.

En paralelo, los modelos fundacionales geoespaciales plantean una forma distinta de representar la información satelital: en lugar de depender únicamente de variables diseñadas manualmente, aprenden representaciones a partir de grandes volúmenes de imágenes, en su mayoría sin etiquetar (Cong et al., 2022; Jakubik et al., 2023; Reed et al., 2023). AlphaEarth Foundations produce, para cada píxel de 10 m, un vector anual de 64 dimensiones que resume observaciones de varios sensores a lo largo del año y que está publicado como una colección abierta en Google Earth Engine (Brown et al., 2025; Gorelick et al., 2017). Debido a que ese vector puede utilizarse como una imagen multibanda, es posible entregarlo directamente como entrada de un clasificador convencional. A partir de ello surge una pregunta central: si esas representaciones aportan información útil que no esté ya contenida en variables espectrales construidas de manera explícita.

Responder esta pregunta requiere controlar la dependencia espacial entre las observaciones. Roberts et al. (2017) muestran que, cuando las observaciones cercanas se parecen entre sí, una validación cruzada aleatoria puede colocar vecinos casi idénticos en entrenamiento y prueba y producir métricas demasiado optimistas. Por esta razón, la evaluación debe separar espacialmente los datos mediante bloques suficientemente grandes para superar el rango de autocorrelación de los residuos. Este control es especialmente importante en el caso de las representaciones aprendidas, porque cada vector puede resumir no solo las características del píxel sino también información de su entorno (Brown et al., 2025). En consecuencia, un punto de validación puede compartir información espacial con puntos utilizados para entrenar aunque no correspondan exactamente a la misma ubicación.

Este trabajo compara enfoques convencionales y modelos fundacionales para el monitoreo del manglar en la CGSM mediante validación espacial explícita, a partir de un cubo de datos multisensor construido para la región. Una comparación inicial entre Sentinel-2 de una sola fecha y AlphaEarth mostró una ventaja de la representación en el régimen principal. Sin embargo, esa comparación dejó dos fuentes de confusión. La primera fue temporal: AlphaEarth resume un año completo, mientras que la línea base de una fecha representaba una única observación, por lo que no fue posible determinar si la mejora provenía de la representación o simplemente de disponer de un periodo de observación más amplio. La segunda fue la referencia, pues se utilizaron etiquetas provenientes de un producto global y no de una interpretación independiente. El presente informe resolvió la primera confusión al construir una línea base espectral que también resumió 2021. La segunda permaneció y, por ello, delimitó el alcance de todas las métricas reportadas.

Pregunta de investigación

¿Aportan las representaciones de un modelo fundacional geoespacial una mejora frente a las variables espectrales convencionales para clasificar coberturas asociadas al manglar en la CGSM cuando la evaluación controla la dependencia espacial entre entrenamiento y validación?

De esta pregunta se derivan tres cuestiones específicas. La primera es si las diferencias de desempeño observadas con particiones aleatorias se mantienen cuando entrenamiento y validación se separan mediante bloques espaciales y mediante una reserva contigua que nunca participa en el entrenamiento. La segunda es si la ventaja de las representaciones preentrenadas persiste cuando Sentinel-2 también resume el mismo año que AlphaEarth, incorporando la estación seca, la estación húmeda y la variabilidad intraanual de 2021. La tercera es si la combinación de ambas fuentes mejora el desempeño predictivo frente a su utilización por separado.

Área de estudio y datos

La CGSM es el sistema lagunar y deltaico más extenso del Caribe colombiano y está reconocida como humedal Ramsar (Blanco-Libreros et al., 2022; Jaramillo et al., 2018). El dominio analítico cubre 2.042 km² (Figura 1) e incluye aproximadamente 317 km² de manglar según Global Mangrove Watch 2020 (Bunting et al., 2022) y 453 km² de espejo lagunar. Dentro del área se localizan estaciones de INVEMAR que registran información sobre la condición estructural del bosque y que permiten contextualizar el área de estudio (INVEMAR, 2024).

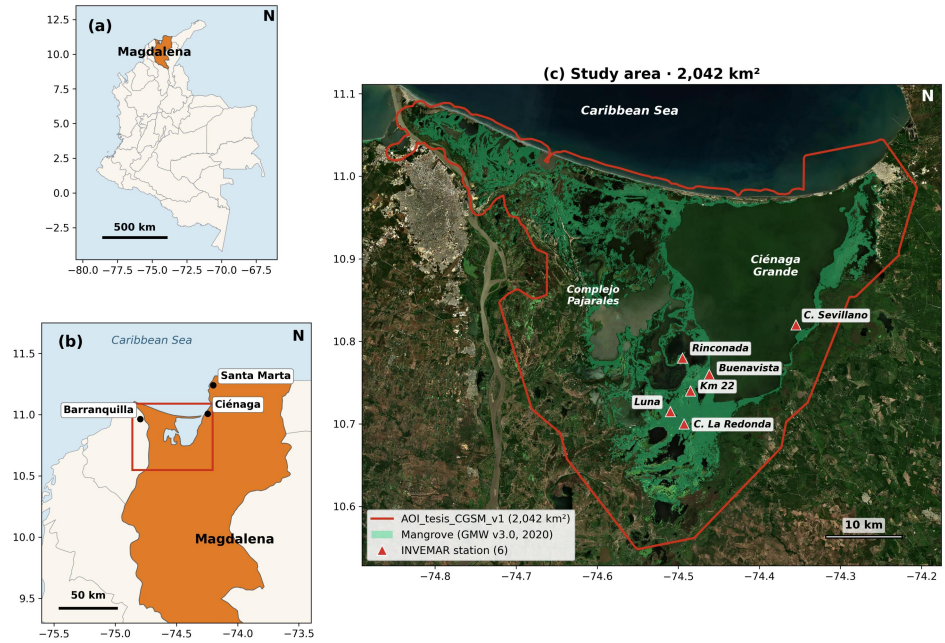


Figure 1. Study area. (a) Magdalena department, Colombia; (b) regional context between Barranquilla and Santa Marta; (c) analytical domain (2,042 km²) and the six INVEMAR monitoring stations. Mangrove extent: Global Mangrove Watch v3.0, 2020 (Bunting et al., 2022). Background: Sentinel-2 cloudless 2024, EOX IT Services GmbH (s. f.), containing modified Copernicus Sentinel data (2024).

Las variables espectrales provinieron del cubo de datos de la CGSM, que organiza compuestos mensuales de Sentinel-2 L2A (Drusch et al., 2012) y Sentinel-1 GRD (Torres et al., 2012) sobre una malla común de 10 m en MAGNA-SIRGAS 2018 origen nacional (EPSG:9377). El cubo contiene compuestos ópticos para 102 de los 121 meses entre diciembre de 2015 y diciembre de 2025 y presenta los doce meses completos para 2021. Cada compuesto óptico incluye las bandas B2, B3, B4, B8, B11 y B12. Una observación corresponde a un compuesto mensual válido. En los 600 puntos utilizados en este informe, la cobertura mensual de 2021 varió entre 573 puntos con información en octubre y 600 puntos en nueve de los doce meses; cada punto tuvo los tres compuestos de la estación seca y, en la húmeda, 573 puntos tuvieron tres y 27 tuvieron dos, de modo que ninguna mediana estacional se calculó con menos de dos compuestos. Sentinel-1 forma parte del cubo, pero no entró en ninguna de las configuraciones comparadas en este informe.

Las representaciones fundacionales provinieron de la colección anual de AlphaEarth disponible en Earth Engine (GOOGLE/SATELLITE_EMBEDDING/V1/ANNUAL). Cada imagen anual incluye 64 dimensiones, A00 a A63, con una resolución espacial de 10 m. Se seleccionó 2021 para hacer coincidir la representación con el año de las etiquetas y con la línea base espectral.

La referencia estuvo constituida por 600 etiquetas débiles derivadas de ESA WorldCover 2021 (Zanaga et al., 2022), balanceadas en 150 puntos por clase para manglar, agua, humedal herbáceo y otro. Las tres primeras corresponden a los códigos 95 (manglar), 80 (agua permanente) y 90 (humedal herbáceo) de

WorldCover, y la clase otro agrupa el resto de coberturas presentes en el dominio: al muestrear el producto en sus 150 puntos, 42 cayeron en bosque (10), 7 en matorral (20), 89 en pastizal (30), 6 en cultivo (40) y 6 en suelo desnudo (60). Los puntos se seleccionaron dentro de vecindades puras de 3 × 3 píxeles; al remuestrear el producto sobre la malla del cubo, 11 de los 450 puntos de las tres clases temáticas quedan sobre un código distinto del esperado; en todos los casos se conservó la etiqueta asignada al generar la muestra, de modo que la discrepancia afecta al muestreo posterior del producto y no a las etiquetas usadas para entrenar y evaluar. Debido a que esta referencia procede de un producto global, las métricas calculadas representan acuerdo con WorldCover y no exactitud temática independiente. Además, el filtro de pureza excluyó muchos píxeles mixtos y de borde, precisamente aquellos en los que la clasificación resulta más difícil.

Metodología

Diseño experimental

El diseño experimental mantuvo constantes todos los elementos posibles para hacer comparable el desempeño de las distintas entradas. Se utilizaron los mismos puntos, las mismas particiones, las mismas métricas y el mismo clasificador; por tanto, las configuraciones se diferenciaron por la información suministrada al modelo, mientras que el procedimiento de entrenamiento y de ajuste de hiperparámetros se mantuvo constante. El clasificador fue un Random Forest con 500 árboles y semilla fija (Breiman, 2001). Sus dos hiperparámetros más influyentes (Belgiu y Drăguţ, 2016) se seleccionaron dentro de cada conjunto de entrenamiento mediante validación cruzada interna agrupada por bloque: el número de variables evaluadas en cada división, entre la raíz cuadrada y la mitad del total, y el tamaño mínimo de hoja, entre 1 y 2. La calibración se realizó exclusivamente dentro de los datos de entrenamiento, por lo que nunca utilizó el pliegue de prueba ni los puntos situados en su zona de exclusión.

Se compararon distintas configuraciones de entrada. Las variantes espectrales aumentaron progresivamente la información temporal disponible: una fecha, una estación, dos estaciones y finalmente una representación multitemporal anual con descriptores fenológicos. Estas configuraciones se contrastaron con AlphaEarth 2021 y con la combinación entre AlphaEarth y la línea base espectral multitemporal. Esta estructura permitió separar dos efectos que la comparación inicial de una sola fecha había mezclado: el beneficio de observar más momentos del año y el beneficio asociado a una representación aprendida.

El Random Forest se mantuvo como clasificador principal para aislar el efecto de las variables de entrada. Como análisis de sensibilidad adicional, se ejecutó un perceptrón multicapa con dos capas ocultas bajo el régimen principal. Este análisis se incluyó a partir de los resultados de Ball et al. (2026), quienes encuentran que la ventaja de algunas representaciones fundacionales puede manifestarse con clasificadores no lineales de mayor capacidad. Sin embargo, el perceptrón utilizó una arquitectura fija y no fue sometido al mismo ajuste de hiperparámetros aplicado al Random Forest. Por esta razón, sus resultados se interpretaron únicamente como una prueba de sensibilidad y no como una comparación formal entre clasificadores.

Muestra y particiones espaciales

Los 600 puntos se dividieron inicialmente en dos grupos. Una reserva contigua de 132 puntos se apartó antes de la validación y se evaluó una sola vez al final. Los 468 puntos restantes se utilizaron para validación cruzada. La reserva se localizó en el sector sur del área etiquetada, incluyó las cuatro clases y permitió responder una pregunta distinta de la validación cruzada: si el modelo podía generalizar hacia un sector continuo que nunca había participado en el entrenamiento. Para evaluarla, el modelo se

entrenó con los 429 de los 468 puntos situados a más de 3 km de la reserva, la misma zona de exclusión del régimen principal.

Sobre los 468 puntos restantes se aplicaron tres esquemas de partición (Figura 2). El primero fue una validación aleatoria en cinco pliegues, sin zona de exclusión. En este esquema, algunos puntos de entrenamiento y prueba quedaron separados por aproximadamente 94 m. Se conservó como una referencia deliberadamente optimista, puesto que no controló la dependencia espacial.

El segundo esquema constituyó el régimen principal. Se utilizaron bloques cuadrados de 6 km que se asignaron completos a cinco pliegues. Además, se excluyeron del entrenamiento todos los puntos situados a menos de 3 km de cualquier bloque de prueba. El tercer esquema fue más exigente y utilizó bloques de 16 km, tres pliegues y una zona de exclusión de 8 km. Este último régimen permitió evaluar cuánto se mantuvo el desempeño cuando los sectores de validación estuvieron espacialmente más alejados de los utilizados para entrenar. La exclusión de 8 km alrededor de bloques de prueba grandes también redujo y desequilibró el entrenamiento: cada pliegue de 16 km entrenó con 95, 142 y 136 puntos, frente a 260 a 296 en los de 6 km, y con alguna clase casi ausente (9 puntos de manglar o 5 de la clase otro en el entrenamiento, frente a más de 50 en la prueba), de modo que en ese régimen cambiaron a la vez la separación espacial, el tamaño y la composición del entrenamiento. Para separar esos efectos se preregistraron tres controles. El primero repitió el régimen de 6 km con el entrenamiento de cada pliegue submuestreado al azar, estratificado por clase, a 95 y a 142 puntos, con 20 repeticiones por tamaño. El segundo lo submuestreó a las cuentas exactas por clase de cada pliegue de 16 km, con 20 repeticiones por composición. El tercero repitió los bloques de 16 km con tres pliegues en diez posiciones de la malla, la original y nueve desplazamientos aleatorios, con la exclusión original de 8 km y con una de 3 km, que ya supera el alcance máximo de los variogramas de los residuos (2.627 m) y es la misma del régimen de 6 km. En los tres se mantuvieron el clasificador, el ajuste de hiperparámetros y los pliegues de prueba, y la regla de lectura se fijó antes de calcular: una ventaja de AlphaEarth de 0,02 o más conservaría la lectura de distancia, una de 0,01 o menos la retiraría y los valores intermedios se reportarían como indeterminados, con umbrales de 0,03 y 0,015 para la combinación.

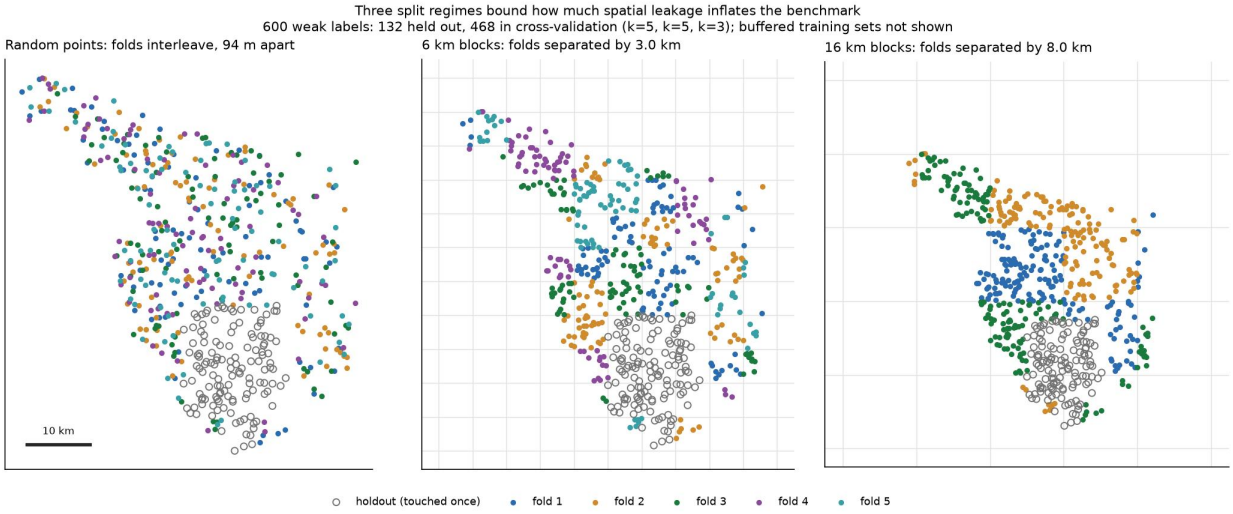


Figure 2. Validation regimes applied to the 468 cross-validation points: random five-fold partitioning; 6 km blocks with a 3 km exclusion buffer; and 16 km blocks with an 8 km exclusion buffer. Open circles are the 132-point contiguous holdout, excluded from cross-validation and evaluated once.

Los tamaños de bloque se fijaron de antemano como un análisis de sensibilidad, porque los variogramas de las propias variables no permitieron derivarlos: ni el NDVI ni la primera componente principal de

AlphaEarth alcanzaron una meseta, crudos ni sin tendencia, y las componentes menores solo la alcanzaron en algunas series, entre 7 y 10 km. Siguiendo a Roberts et al. (2017), lo que debe ser independiente entre pliegues es el residuo del modelo y no el predictor, de modo que el bloque de 6 km se comprobó después con los variogramas del indicador de error de clasificación fuera de pliegue de los modelos finales del propio régimen de 6 km, con el mismo estimador de la comparación inicial (14 rezagos, ventana del 30 % de la extensión): los residuos alcanzaron la meseta a 525 m para la línea base multitemporal y para la combinación, y a 2.627 m para AlphaEarth, frente a 1.576 m y 2.627 m en la comparación inicial de una sola fecha. Todos los valores fueron menores que el lado del bloque y que la zona de exclusión de 3 km impuesta entre entrenamiento y prueba. El alcance de los residuos de AlphaEarth fue el mayor de los tres, por lo que ese alcance es el que orienta la separación entre entrenamiento y validación.

Línea base espectral multitemporal

Las variables espectrales se reconstruyeron a partir de las bandas originales del cubo para dejar documentada cada transformación. Las seis reflectancias se dividieron por 10.000 y, a partir de ellas, se calcularon NDVI (Rouse et al., 1973), NDWI utilizando verde e infrarrojo cercano (McFeeters, 1996) y MNDWI utilizando verde e infrarrojo de onda corta (Xu, 2006). CMRI (Gupta et al., 2018), definido como la diferencia NDVI − NDWI, se excluyó porque corresponde a una combinación lineal exacta de dos variables ya incluidas y, por tanto, habría añadido redundancia sin incorporar información independiente.

Para que Sentinel-2 cubriera el mismo periodo anual que AlphaEarth, se construyeron tres componentes temporales. La estación seca se representó mediante la mediana por banda de enero, febrero y marzo de 2021. La estación húmeda se representó con septiembre, octubre y noviembre. Sobre ambas medianas se recalcularon NDVI, NDWI y MNDWI. La dinámica intraanual se resumió a partir de los doce compuestos mensuales mediante cuatro descriptores de cada índice: mínimo, máximo, amplitud y desviación estándar.

A partir de estos componentes se evaluaron cinco variantes espectrales. Marzo de 2021 utilizó nueve variables y correspondió a la comparación inicial de una sola fecha. La estación seca y la estación húmeda se evaluaron por separado, también con nueve variables cada una. La combinación seca + húmeda incluyó 18 variables. Finalmente, seca + húmeda + fenología reunió 30 variables y constituyó la línea base espectral más completa para la comparación con AlphaEarth.

Representaciones fundacionales

AlphaEarth se muestreó en Google Earth Engine exactamente sobre los mismos 600 puntos utilizados en la línea base espectral. La proyección y la transformación de la malla del cubo se declararon explícitamente para evitar desplazamientos entre ambas fuentes. Este control fue importante porque un desplazamiento de medio píxel habría sido suficiente para que Sentinel-2 y AlphaEarth describieran ubicaciones diferentes.

Antes de exportar se verificó la alineación espacial. Se exportaron únicamente los valores correspondientes a los 600 puntos y no la imagen completa de 64 bandas, ya que el experimento no requería los más de 11 GB que habría ocupado el dominio completo. Después de la exportación se comprobó, punto por punto, que las coordenadas y la clase asignada coincidieran entre ambas fuentes.

TESSERA (Feng et al., 2026) se había considerado como una segunda representación fundacional, pero no se incorporó en este informe porque su cobertura de 2021 fue incompleta. Solo cubrió 305 de los 600 puntos y lo hizo de manera desigual entre clases. Una validación espacial realizada sobre ese subconjunto habría reducido la potencia del experimento y habría impedido una comparación directa con las demás configuraciones. Por esta razón, su evaluación se pospuso hasta disponer de un año con cobertura completa y de una referencia independiente adecuada.

Métricas y comparación

El desempeño se evaluó mediante exactitud global, F1 por clase y macro-F1. El macro-F1 se utilizó como métrica principal porque asigna el mismo peso a las cuatro clases y evita que el alto desempeño en agua, prácticamente saturado en todas las configuraciones, dominara la evaluación. El coeficiente kappa se incluyó por convención, pero no se utilizó para interpretar las diferencias entre configuraciones, siguiendo a Foody (2020). La importancia de variables se tomó de la reducción media de impureza del Random Forest; como ese procedimiento reparte el peso entre predictores correlacionados, se usó para describir el reparto entre fuentes y no como medida de la información que aporta cada una.

Como todas las configuraciones se evaluaron sobre exactamente los mismos puntos y pliegues, la comparación se realizó de forma pareada. En un primer nivel se calculó, dentro de cada pliegue, la diferencia de macro-F1 frente a la línea base. Se reportaron la diferencia media, su desviación estándar pareada y el número de pliegues en los que cada configuración obtuvo un mejor resultado. Esta desviación describe la estabilidad de la diferencia entre entradas y no la variabilidad de cada configuración considerada por separado. Con solo cinco pliegues, este nivel de análisis aporta principalmente información sobre la dirección, magnitud y consistencia del efecto. Las diferencias de la Tabla 3 son el promedio de las diferencias por pliegue (por ejemplo, 0,039 y 0,003 para AlphaEarth a 6 y 16 km), mientras que las citadas en el resumen y en el texto corresponden al macro-F1 agregado sobre las predicciones fuera de pliegue (0,038 y 0,004); son estimadores distintos de la misma comparación.

En un segundo nivel se compararon las predicciones punto a punto mediante la prueba de McNemar sobre pares discordantes (Foody, 2004). La prueba principal se aplicó sobre las 468 predicciones fuera de pliegue del régimen de bloques, de manera que cada punto fue predicho por un modelo que nunca había utilizado su bloque ni la zona de exclusión de 3 km durante el entrenamiento. La reserva contigua de 132 puntos también se evaluó, aunque tuvo menor potencia por su tamaño.

Puesto que la prueba de McNemar trata cada punto como una observación independiente y los puntos vecinos no lo son, las comparaciones del análisis principal se repitieron con una prueba de permutación pareada en la que la unidad intercambiada fue el bloque espacial del régimen y no el punto. En cada una de 20.000 repeticiones se intercambiaron al azar, bloque por bloque, las predicciones de la línea base y las de la otra configuración, y se recalculó la diferencia de macro-F1. El intervalo de esa diferencia se obtuvo por remuestreo de bloques con reemplazo. La misma comprobación se aplicó a las dos pruebas de sensibilidad.

Los 468 puntos no son completamente independientes porque los puntos pertenecientes a un mismo pliegue comparten el modelo con el que fueron predichos. Por esta razón, los valores p cercanos al umbral se interpretaron con cautela. Finalmente, los conteos por clase no se transformaron en estimaciones de superficie, ya que esa inferencia requiere una muestra probabilística y una corrección basada en la matriz de confusión, como plantean Olofsson et al. (2014).

Resultados

Perfil temporal de 2021 en los puntos de referencia

La Figura 3 muestra, para cada clase, la mediana mensual y el rango intercuartílico de NDVI, NDWI y MNDWI durante 2021. El manglar presentó una señal relativamente estable: su NDVI varió entre 0,69 en abril y 0,86 en diciembre y mostró medianas casi idénticas en las ventanas seca (0,80) y húmeda (0,79). El humedal herbáceo se mantuvo por debajo del manglar, aunque sus rangos se solaparon. La clase otro presentó la mayor dinámica estacional: pasó de 0,58 en la ventana seca a 0,73 en la húmeda y alcanzó 0,77 en agosto, comportamiento compatible con pastos y cultivos que reverdecen con la lluvia. En agua, el MNDWI descendió de 0,81 en diciembre a 0,40 en octubre, precisamente el mes con menor cobertura

de datos. Este descenso pudo combinar cambios reales, como turbidez o vegetación flotante, con contaminación residual de nubes.

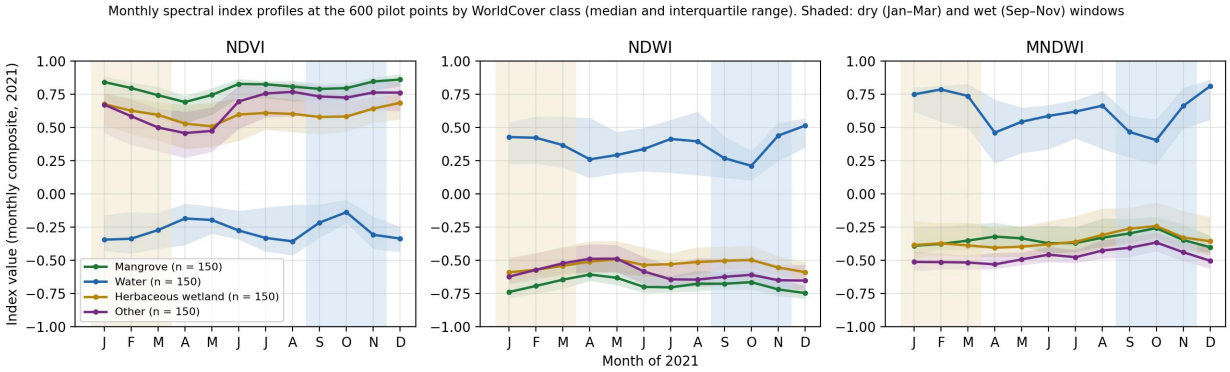


Figure 3. Monthly profiles of NDVI, NDWI and MNDWI at the 600 points by WorldCover 2021 class (median and interquartile range). Shaded windows mark the dry (January–March) and wet (September–November) seasons used to build the baseline.

Estas curvas muestran dónde puede aportar información la dimensión temporal. Manglar y humedal herbáceo se separaron mejor en diciembre y enero que en mayo. La clase otro se distinguió del humedal principalmente por su variación a lo largo del año.

Línea base espectral por régimen de validación

La Tabla 1 reúne los resultados de las variantes espectrales bajo los cuatro regímenes de validación. La configuración de marzo, que corresponde a la comparación inicial de una sola fecha, obtuvo 0,835 de macro-F1 con partición aleatoria, 0,795 con bloques de 6 km, 0,733 con bloques de 16 km y 0,676 en la reserva. Estos valores coincidieron con los de la comparación inicial, que había utilizado un GeoTIFF local del cubo, mientras que el presente informe muestreó los compuestos publicados en Earth Engine; por tanto, se confirmó que ambas fuentes contenían los mismos valores en los 600 puntos.

Tabla 1. Macro-F1 de la línea base espectral por configuración y régimen de validación (468 puntos de validación cruzada y 132 de reserva, etiquetas WorldCover 2021). La desviación estándar corresponde a los cinco pliegues de 6 km.

Configuración	Variables	Aleatorio	Bloques 6 km	sd 6 km	Bloques 16 km	Reserva (n = 132)
Marzo 2021	9	0,835	0,795	0,046	0,733	0,676
Estación seca	9	0,833	0,810	0,052	0,704	0,694
Estación húmeda	9	0,776	0,756	0,026	0,687	0,699
Seca + húmeda	18	0,854	0,804	0,031	0,710	0,740
Seca + húmeda + fenología	30	0,851	0,808	0,047	0,703	0,758

En los bloques de 6 km, las variantes espectrales presentaron resultados similares dentro de la variación entre pliegues. La estación seca alcanzó 0,810 de macro-F1 y la configuración multitemporal completa obtuvo 0,808, frente a 0,795 con marzo. Estas diferencias de una o dos centésimas fueron menores que la desviación entre pliegues, que varió entre 0,026 y 0,052. La estación húmeda fue la configuración más débil en todos los regímenes, con 0,756 a 6 km. Su principal pérdida ocurrió en el humedal herbáceo, cuyo F1 descendió a 0,584 frente a 0,653 con marzo. Dado que octubre combinó la menor cobertura de datos con el mayor cambio del MNDWI en agua, parte de esta caída pudo estar relacionada con la calidad del compuesto húmedo y no exclusivamente con la fenología.

La reserva contigua mostró una diferencia que no había aparecido con igual claridad en la validación cruzada. Sobre los 132 píxeles nunca utilizados para entrenar, la configuración multitemporal completa alcanzó 0,758 de macro-F1 frente a 0,676 con marzo, lo que correspondió a una mejora de 0,082. En la prueba de McNemar, 21 puntos fueron acertados únicamente por la configuración multitemporal y 8

únicamente por marzo (p = 0,024). La combinación seca + húmeda, sin descriptores fenológicos, obtuvo 0,740 y presentó 19 frente a 9 discordantes (p = 0,087). Entre seca + húmeda y la configuración completa solo se observaron 5 frente a 2 discordantes (p = 0,45). Estos resultados indicaron que incorporar dos estaciones aportó información frente a una única fecha, mientras que las doce variables fenológicas añadieron relativamente poco sobre esas dos ventanas.

Con base en estos resultados, la configuración seca + húmeda + fenología, con 30 variables, se adoptó como línea base espectral para la comparación con AlphaEarth. Esta configuración obtuvo el mejor desempeño en la reserva y su mejora frente a marzo estuvo respaldada por la prueba de McNemar. En los bloques de 6 km presentó diferencias pequeñas frente a las demás variantes en relación con la variabilidad entre pliegues y, sobre todo, resumió el mismo periodo anual que la representación fundacional. De esta manera se evitó atribuir a AlphaEarth una ventaja que en realidad pudiera haber provenido de observar un periodo temporal más largo.

Representaciones frente a variables espectrales

La Tabla 2 y la Figura 4 comparan las entradas espectrales, AlphaEarth y la combinación entre ambas fuentes bajo los cuatro regímenes de validación. Frente a la línea base multitemporal, AlphaEarth mejoró el macro-F1 en 0,038 con bloques de 6 km, en 0,036 con partición aleatoria, en 0,023 en la reserva y en apenas 0,004 con bloques de 16 km. La combinación de ambas fuentes alcanzó 0,863 a 6 km y 0,738 a 16 km, el mayor macro-F1 también en el régimen de 16 km original, cuya lectura se matiza más adelante por el tamaño y la composición del entrenamiento.

Tabla 2. Macro-F1 por configuración de entrada y régimen de validación, con los mismos 468 puntos de validación cruzada y 132 de reserva, los mismos pliegues y el mismo Random Forest (etiquetas WorldCover 2021). La desviación estándar corresponde a los cinco pliegues de 6 km.

Configuración	Variables	Aleatorio	Bloques 6 km	sd 6 km	Bloques 16 km	Reserva (n = 132)
Sentinel-2, marzo	9	0,835	0,795	0,046	0,733	0,676
Sentinel-2, seca + húmeda	18	0,854	0,804	0,031	0,710	0,740
Sentinel-2, multitemporal	30	0,851	0,808	0,047	0,703	0,758
AlphaEarth 2021	64	0,887	0,846	0,077	0,708	0,781
Multitemporal + AlphaEarth	94	0,882	0,863	0,071	0,738	0,762

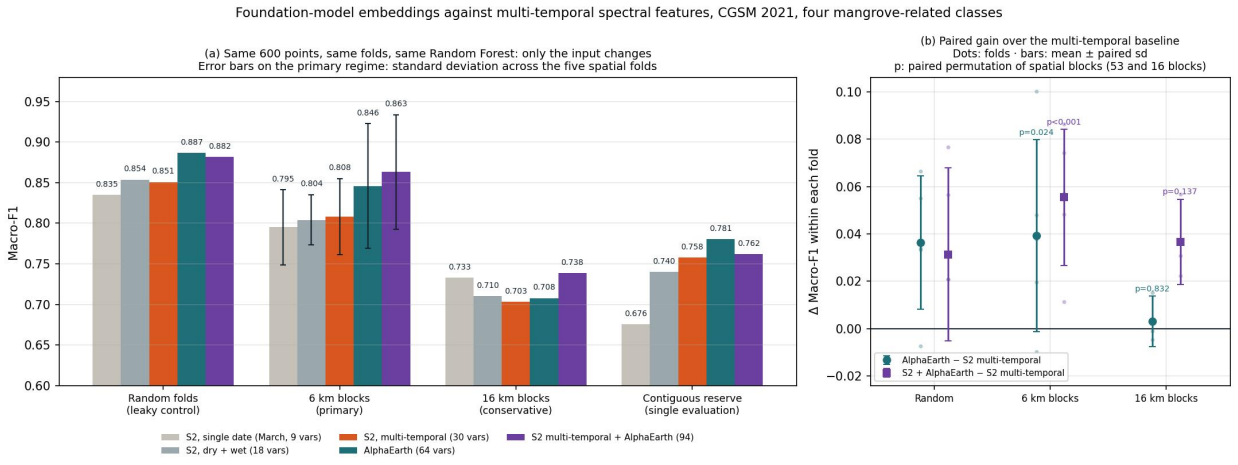


Figure 4. Macro-F1 by input configuration and validation regime over the same folds and Random Forest (468 cross-validation points; the reserve uses the other 132). Panel (b) shows the paired gain over the multi-temporal spectral baseline within each fold, with the standard deviation of that difference and the p-value of the paired permutation of spatial blocks over the 468 out-of-fold predictions.

La comparación pareada, resumida en la Tabla 3, permitió precisar estas diferencias. Con bloques de 6 km, AlphaEarth mejoró en promedio 0,039 de macro-F1 dentro de cada pliegue, con una desviación pareada de 0,041, y superó a la línea base en cuatro de cinco pliegues. La variación de esta diferencia fue considerablemente menor que la desviación de AlphaEarth considerada por separado, que alcanzó 0,077, porque parte de la dificultad espacial afectó de manera similar a ambas configuraciones. La combinación multitemporal + AlphaEarth presentó un comportamiento más consistente: mejoró 0,055, tuvo una desviación pareada de 0,029 y superó a la línea base en los cinco pliegues.

Tabla 3. Comparación pareada frente a la línea base multitemporal: diferencia media de macro-F1 por pliegue y su desviación, pliegues ganados, pares discordantes de McNemar (solo línea base / solo la otra configuración) sobre las 468 predicciones fuera de pliegue, y p de la permutación por bloques (53 de 6 km, 16 de 16 km). AE = AlphaEarth.

Configuración	Régimen	Dif. media	sd pareada	Pliegues	Discordantes (base / otro)	p McNemar	p permutación
AlphaEarth	Aleatorio	+0,036	0,028	4 de 5	—	—	—
AlphaEarth	Bloques 6 km	+0,039	0,041	4 de 5	22 / 39	0,040	0,024
AlphaEarth	Bloques 16 km	+0,003	0,011	1 de 3	37 / 41	0,734	0,832
Multitemporal + AE	Aleatorio	+0,031	0,037	4 de 5	—	—	—
Multitemporal + AE	Bloques 6 km	+0,055	0,029	5 de 5	6 / 31	0,00004	0,0001
Multitemporal + AE	Bloques 16 km	+0,037	0,018	3 de 3	18 / 34	0,036	0,137

Sobre las 468 predicciones fuera de pliegue del régimen principal, AlphaEarth acertó 39 puntos que la línea base falló, mientras que la línea base acertó 22 puntos que AlphaEarth falló. La prueba de McNemar produjo p = 0,040. En la combinación de ambas fuentes, 31 puntos fueron acertados únicamente por la combinación y 6 únicamente por la línea base, con p = 0,00004. Por tanto, con una separación espacial de 6 km, AlphaEarth aportó una mejora detectable y la combinación produjo una diferencia más consistente.

La caída a 16 km exige una lectura aparte, porque en ese régimen cada pliegue entrenó con 95 a 142 puntos, frente a 260 a 296 a 6 km, y con alguna clase casi ausente: el pliegue 1 aprendió el manglar con 9 puntos y lo evaluó sobre 53, y el pliegue 2 aprendió la clase otro con 5 y la evaluó sobre 52. Tres controles separaron los efectos (Tabla 4). Con el entrenamiento de 6 km submuestreado a 95 y 142 puntos en proporción de clases, la ventaja de AlphaEarth bajó de 0,038 a 0,018 y 0,025, positiva en 16 y 19 de 20 repeticiones; con el tamaño y la composición exacta de cada pliegue de 16 km bajó a 0,006 en conjunto (0,024 con la composición equilibrada del pliegue 0, 0,001 y −0,007 con las dos desequilibradas) y la macro-F1 de la línea base cayó a 0,68 y 0,78, cerca del 0,70 del régimen de 16 km. Por tanto, el nivel del régimen de 16 km original refleja la exclusión de 8 km, tres veces el alcance máximo de los variogramas de los residuos, y no la separación espacial. El tercer control repitió los bloques de 16 km con exclusión de 3 km y diez posiciones de la malla: el entrenamiento subió a 249 puntos por pliegue en promedio, con 41 puntos de la clase menos representada, la macro-F1 volvió al nivel de 6 km (0,814 la línea base, 0,807 AlphaEarth y 0,821 la combinación) y, promediando las mallas, AlphaEarth quedó 0,007 por debajo de la línea base, con intervalo de −0,031 a 0,021 y ventaja positiva en 4 de diez mallas, y la combinación 0,007 por encima, de −0,017 a 0,031 y positiva en 6. Con la exclusión original de 8 km la diferencia de AlphaEarth varió entre −0,023 y 0,041 según la malla, de modo que el resultado de una sola malla depende de dónde caen los bloques. Según las reglas fijadas de antemano, a 16 km con entrenamiento adecuado ni AlphaEarth ni la combinación conservan la ventaja observada a 6 km.

Tabla 4. Controles del régimen de 16 km. Arriba, régimen de 6 km con el entrenamiento de cada pliegue submuestreado por tamaño (142 y 95 puntos, 20 repeticiones) y por tamaño y composición de clases de cada pliegue de 16 km (60 repeticiones). Abajo, bloques de 16 km con tres pliegues en diez posiciones de la malla, con la exclusión original de 8 km y con la de 3 km. Macro-F1 medio sobre las

predicciones fuera de pliegue, diferencia pareada frente a la línea base multitemporal con intervalo percentil 2,5 a 97,5 entre repeticiones o mallas, y número de repeticiones o mallas con diferencia positiva. AE = AlphaEarth.

Régimen y entrenamiento por pliegue	Línea base	AE	Multitemporal + AE	Dif. AE	Dif. multitemporal + AE
6 km completo (260 a 296 puntos)	0,808	0,846	0,863	+0,038	+0,055
6 km, 142 puntos	0,805	0,829	0,833	+0,025 [−0,002 a 0,053] (19/20)	+0,028 [0,007 a 0,045] (20/20)
6 km, 95 puntos	0,798	0,816	0,825	+0,018 [−0,017 a 0,053] (16/20)	+0,027 [0,001 a 0,054] (19/20)
6 km, tamaño y composición de los pliegues de 16 km (95 a 136)	0,756	0,762	0,771	+0,006 [−0,040 a 0,044] (36/60)	+0,015 [−0,023 a 0,045] (50/60)
16 km original, exclusión 8 km, malla del informe (95 a 142)	0,703	0,708	0,738	+0,004	+0,035
16 km, exclusión 8 km, diez mallas (102 en promedio)	0,738	0,741	0,746	+0,003 [−0,023 a 0,041] (5/10)	+0,008 [−0,030 a 0,039] (7/10)
16 km, exclusión 3 km, diez mallas (249 en promedio)	0,814	0,807	0,821	−0,007 [−0,031 a 0,021] (4/10)	+0,007 [−0,017 a 0,031] (6/10)

La permutación por bloques confirmó el segundo resultado y matizó el primero. Con los 53 bloques de 6 km, la diferencia de macro-F1 de la combinación fue de 0,055, con un intervalo del 95 % entre 0,031 y 0,080 y p = 0,0001, y la de AlphaEarth fue de 0,038, con un intervalo entre 0,006 y 0,068 y p = 0,024. No obstante, el resultado de AlphaEarth dependió de la unidad espacial de la permutación: al agrupar los mismos puntos en unidades de 12 y 16 km, su valor p ascendió a 0,059 y 0,187, mientras que el de la combinación se mantuvo en 0,0016 y 0,0086. Las unidades mayores reducen el número de bloques y con él la potencia, de modo que ese ascenso no permite separar la dependencia espacial corregida de la potencia perdida. En consecuencia, la mejora de la combinación a 6 km se sostuvo bajo todas las variantes y la de AlphaEarth sola constituye evidencia débil.

Al aumentar la separación espacial, la ventaja de AlphaEarth sola se redujo hasta no distinguirse del azar. Con bloques de 16 km, la diferencia media por pliegue frente a la línea base descendió a 0,003, la representación superó a la línea base en solo uno de los tres pliegues y McNemar produjo p = 0,734. La combinación, en cambio, conservó una mejora de 0,037, ganó los tres pliegues y McNemar produjo p = 0,036. Sin embargo, con solo 16 bloques de 16 km la permutación por bloques produjo p = 0,137, con un intervalo para la diferencia entre −0,004 y 0,067, de modo que a esa separación la mejora conservó su magnitud y su signo pero no se distinguió del azar. El resultado que mejor resistió la validación por bloques fue, por tanto, la complementariedad entre ambas fuentes y no la sustitución de las variables espectrales por AlphaEarth, aunque a 16 km lo que persiste es el efecto observado en una sola malla, que el régimen corregido no confirma.

En la reserva contigua de 132 puntos no se detectaron diferencias claras entre las configuraciones. AlphaEarth acertó 14 puntos que la línea base falló y falló 12 que la línea base acertó (p = 0,85). La combinación presentó 8 frente a 9 discordantes (p = 1,00). Estos resultados no demostraron que las configuraciones fueran equivalentes, porque la reserva reunió aproximadamente una cuarta parte de los puntos y proporcionó una única evaluación, por lo que tuvo menor capacidad para detectar diferencias pequeñas.

AlphaEarth también presentó una mayor variabilidad entre sectores. En tres pliegues alcanzó valores de macro-F1 entre 0,875 y 0,904, pero en el primero descendió a 0,723, por debajo del 0,732 obtenido por la línea base espectral. Así, la representación mejoró el desempeño promedio bajo el régimen principal, pero esa ventaja no fue espacialmente uniforme.

La mejora se concentró en las clases más difíciles. Con bloques de 6 km, el F1 del humedal herbáceo aumentó de 0,667 con la línea base a 0,744 con AlphaEarth y a 0,776 con la combinación. En manglar aumentó de 0,807 a 0,856 y 0,873, respectivamente. El agua permaneció prácticamente saturada, entre 0,968 y 0,969, por lo que no explicó la mejora del macro-F1. En la reserva el patrón fue menos uniforme: AlphaEarth mejoró el humedal herbáceo y la clase otro, pero obtuvo un F1 menor que la línea base en manglar, con 0,845 frente a 0,883.

Dos resultados respaldaron la interpretación de complementariedad. En primer lugar, la combinación superó a AlphaEarth sola en los dos regímenes de bloques, con 0,863 frente a 0,846 a 6 km, 0,738 frente a 0,708 a 16 km y 0,821 frente a 0,807 en el régimen de 16 km corregido. En segundo lugar, cuando ambas fuentes se utilizaron juntas, las 64 dimensiones de AlphaEarth reunieron el 49 % de la importancia total a pesar de representar el 68 % de las variables. Cuatro de las cinco variables más importantes fueron espectrales, encabezadas por el infrarrojo de onda corta de la estación seca y por el máximo anual del índice de agua. Estos resultados son compatibles con una contribución predictiva complementaria de ambas fuentes, aunque la importancia por impureza no permite cuantificar la información independiente de cada una.

El F1 de cada clase es la media armónica de su precisión y su exhaustividad, y el macro-F1 es el promedio de los cuatro F1 con el mismo peso. La Tabla 5 los desagrega para el régimen principal: el agua está saturada en todas las configuraciones, el manglar y la clase otro ganan con AlphaEarth y con la combinación, y el humedal herbáceo es la clase más baja en todas y la que más mejora, de 0,667 a 0,776.

Tabla 5. F1 por clase y macro-F1 de las cinco configuraciones con bloques de 6 km (468 puntos de validación cruzada, etiquetas WorldCover 2021).

Configuración	Manglar	Agua	Humedal herbáceo	Otro	Macro-F1
Sentinel-2, marzo	0,795	0,961	0,653	0,772	0,795
Sentinel-2, seca + húmeda	0,818	0,969	0,645	0,785	0,804
Sentinel-2, multitemporal	0,807	0,969	0,667	0,791	0,808
AlphaEarth 2021	0,856	0,968	0,744	0,815	0,846
Multitemporal + AlphaEarth	0,873	0,969	0,776	0,835	0,863

Aplicación espacial de las configuraciones

La Figura 5 extiende las tres configuraciones principales a toda el área de estudio. Para procesar los aproximadamente 20 millones de píxeles de 10 m del dominio analítico (43 millones en la ventana rectangular del cubo) se utilizó el Random Forest de Earth Engine, entrenado con los mismos 429 puntos de la partición de la reserva (los 468 de validación cruzada menos los 39 situados a menos de 3 km de ella), las mismas variables y los mismos hiperparámetros utilizados en scikit-learn. Sobre los 132 puntos reservados, ambos motores coincidieron en 96,2 % de las predicciones para la línea base y AlphaEarth y en 97,7 % para la combinación.

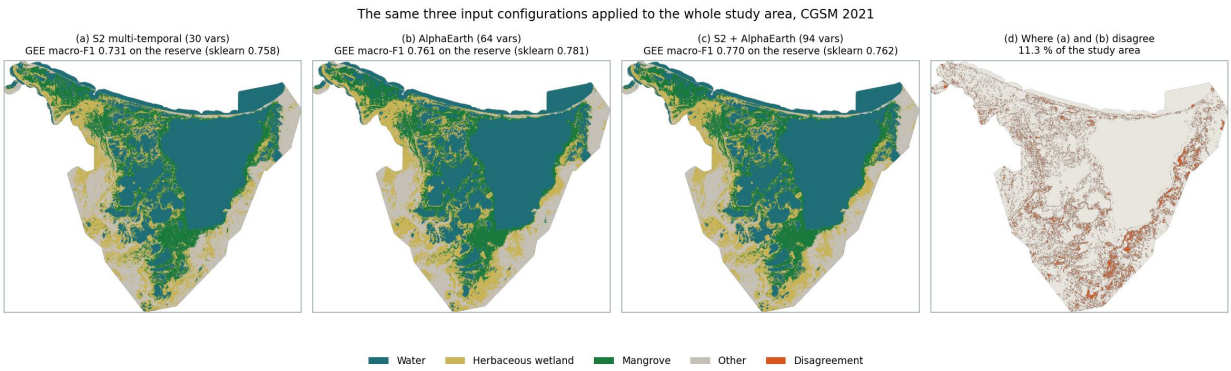


Figure 5. The three input configurations applied to the whole study area with the Earth Engine Random Forest trained on the same 429 points (the 468 cross-validation points minus the 39 within 3 km of the reserve), variables and hyperparameters. Titles give the macro-F1 of each map on the 132 reserve points and, in brackets, that of the scikit-learn model reported in Table 2. Panel (d) marks the pixels where the spectral baseline and AlphaEarth assign different classes.

El orden relativo entre la línea base y AlphaEarth se conservó al cambiar de motor. En cambio, AlphaEarth y la combinación intercambiaron su posición relativa, lo que indicó que la pequeña diferencia entre estas dos configuraciones estuvo dentro de la variación introducida por la implementación.

La línea base y AlphaEarth asignaron clases distintas al 11,3 % del área. Casi todo el desacuerdo involucró al humedal herbáceo: los intercambios humedal–otro sumaron 5,1 % del área, humedal–manglar 4,1 % y humedal–agua 1,8 %. Espacialmente, las diferencias se concentraron en las márgenes oriental y suroriental de la ciénaga, hacia los ríos que descienden de la Sierra Nevada de Santa Marta, y en el mosaico del sector occidental. No se concentraron en el interior del manglar.

En consecuencia, ambas entradas coincidieron en términos generales en la localización del bosque y difirieron principalmente en la manera de representar la vegetación herbácea inundable que lo rodea. Esta fue, además, la clase en la que AlphaEarth produjo la mayor mejora de F1. Las proporciones obtenidas en los mapas no se interpretaron como estimaciones de superficie porque la muestra utilizada no había sido diseñada para ese propósito.

Análisis de sensibilidad con perceptrón multicapa

El análisis con el perceptrón multicapa no reprodujo el patrón descrito por Ball et al. (2026). Con bloques de 6 km obtuvo 0,808 de macro-F1 con AlphaEarth, 0,809 con la combinación y 0,630 con la línea base espectral, todos por debajo del Random Forest, con una caída pequeña para las representaciones (0,038 y 0,054) y grande para las variables espectrales (0,178). AlphaEarth conservó así su ventaja frente a la línea base y las representaciones resultaron menos sensibles a un clasificador sin ajuste; como el perceptrón usó una arquitectura fija sin calibración, el resultado no permite conclusiones generales sobre el efecto de la complejidad del clasificador.

Sensibilidad a la calidad de las etiquetas

Las etiquetas se contrastaron con dos productos cartográficos elaborados de forma independiente de WorldCover, que tampoco son mediciones de terreno. Frente a Global Mangrove Watch 2020 (Bunting et al., 2022), el 79 % de los puntos de manglar cayó dentro del manglar cartografiado, mientras que lo hicieron el 13 % de los puntos de humedal herbáceo, el 9 % de los de la clase otro y el 4 % de los de agua. Frente a la clase modal de Dynamic World 2021 (Brown et al., 2022), el agua coincidió en el 95 % de los puntos y el humedal herbáceo fue la clase menos consistente: 64 de sus 150 puntos correspondieron a árboles. La clase con más ruido de etiqueta coincide, por tanto, con aquella en la que AlphaEarth mostró la mayor ganancia.

Para comprobar si las conclusiones dependían de ese ruido, la comparación se repitió sin los 77 puntos cuya etiqueta contradecía a Global Mangrove Watch o, en el caso del agua, a Dynamic World, con los mismos pliegues, la misma reserva y el mismo clasificador. Todas las configuraciones subieron cerca de 0,04 de macro-F1. Con bloques de 6 km, AlphaEarth superó a la línea base en los cinco pliegues, con una diferencia media de 0,036 y p = 0,029 en la prueba de McNemar sobre 415 predicciones fuera de pliegue, y la combinación lo hizo con 0,040 y p = 0,0015. Con bloques de 16 km, la ventaja de AlphaEarth siguió ausente, con 0,001 y p = 0,73. La combinación conservó una diferencia positiva de 0,024 y superó a la línea base en dos de los tres pliegues, pero McNemar dejó de indicar una diferencia significativa (p = 0,18). En la reserva, ninguna de las dos configuraciones se separó de la línea base. La permutación por bloques dio p = 0,024 para AlphaEarth y p = 0,0003 para la combinación a 6 km, y p = 0,82 y p = 0,47 a 16 km. En consecuencia, el patrón general se conservó con las etiquetas depuradas, y la mejora de la combinación a 16 km siguió sin respaldo de la permutación por bloques, como antes del filtrado.

Sensibilidad al número de pliegues

El régimen principal se repitió repartiendo los mismos bloques de 6 km en diez pliegues en lugar de cinco, con la misma zona de exclusión de 3 km, los mismos puntos y el mismo clasificador. El cambio no altera la separación espacial entre entrenamiento y prueba, pero sí la composición y el tamaño de cada conjunto de entrenamiento: la mediana del tamaño pasó de 270 a 362 puntos, porque con bloques de prueba más pequeños la zona de exclusión retira menos puntos del entrenamiento.

Con diez pliegues, la línea base espectral subió de 0,803 a 0,830 de macro-F1 promedio por pliegue, mientras que AlphaEarth se mantuvo alrededor de 0,84, con 0,842 y 0,833. La diferencia entre ambas se redujo a 0,003, AlphaEarth ganó en cinco de los diez pliegues y la prueba de McNemar no detectó diferencia, con 30 frente a 33 discordantes y p = 0,80. La combinación conservó una diferencia de 0,022, ganó en seis de diez pliegues y tampoco alcanzó significancia, con p = 0,16. La permutación por bloques coincidió, con p = 0,61 para AlphaEarth y p = 0,12 para la combinación, cuya diferencia de macro-F1 tuvo un intervalo del 95 % entre −0,006 y 0,050.

Al aumentar la mediana del entrenamiento de 270 a 362 puntos mejoró el desempeño de la línea base espectral, mientras que el de AlphaEarth permaneció estable, de modo que la ventaja de AlphaEarth es compatible con la eficiencia de etiquetas y no con el techo de desempeño, aunque el cambio de pliegues también modificó la composición del entrenamiento y no aísla el tamaño como único factor. Ball et al. (2026) describen el mismo comportamiento al reportar que las representaciones se acercan a la saturación con el 5 % de las parcelas de entrenamiento.

Discusión

El experimento permitió evaluar cuánto cambiaba la ventaja inicial de AlphaEarth al compararla con una línea base espectral que también resumía 2021. En esa comparación, AlphaEarth había superado a Sentinel-2 de una sola fecha por 0,051 de macro-F1 en los bloques de 6 km y por 0,105 en la reserva. Cuando Sentinel-2 incorporó información correspondiente a todo 2021, estas diferencias disminuyeron a 0,038 y 0,023, respectivamente. Esto indicó que una parte importante de la ventaja inicial no había provenido exclusivamente de la representación fundacional, sino de comparar un resumen anual con una única fecha. La reducción equivalió aproximadamente a una cuarta parte de la ventaja inicial a 6 km y a cuatro quintas partes en la reserva, aunque el contraste no permite atribuir esas proporciones exclusivamente a la cobertura temporal, porque la línea base multitemporal también cambió el número de variables. Frente a una línea base espectral que también resumió 2021, AlphaEarth conservó una mejora de menor magnitud.

La magnitud de esta mejora dependió de la distancia entre entrenamiento y evaluación y de la unidad de inferencia. La ventaja de AlphaEarth sola fue detectable a 6 km en la comparación pareada y en la

permutación por bloques, se debilitó al pasar la unidad de permutación a bloques de 16 km y desapareció en el régimen de 16 km, tanto en el original como en el corregido con exclusión de 3 km y diez mallas. En consecuencia, los resultados no respaldaron una afirmación general de superioridad de AlphaEarth frente a una línea base espectral del mismo periodo.

La complementariedad constituye el resultado más sólido del informe. La combinación de AlphaEarth con las variables espectrales superó a la línea base en todos los pliegues de 6 km con respaldo estadístico y en los tres de la malla original de 16 km sin él; en el régimen de 16 km corregido no superó a la línea base de forma consistente, y la importancia de variables se repartió aproximadamente por mitades entre ambas fuentes. En conjunto, AlphaEarth no funcionó como un reemplazo de las variables espectrales sino como una fuente adicional que pudo integrarse con ellas. Las pruebas de sensibilidad acotan el resultado sin cambiarlo: sin los 77 puntos en conflicto y con diez pliegues, la combinación siguió siendo la mejor configuración en los regímenes de bloques, con significancia a 6 km y no a 16 km; no fue la mejor en la partición aleatoria ni en la reserva, donde AlphaEarth sola la superó. El experimento de diez pliegues añade una lectura: con los mismos bloques y la misma zona de exclusión pero más puntos de entrenamiento, la línea base espectral recuperó la diferencia mientras la representación se mantuvo en su nivel, el comportamiento que Ball et al. (2026) describen como eficiencia de etiquetas, aunque los controles con menos entrenamiento (Tabla 4) no mostraron el lado complementario de ese patrón, porque la ventaja de AlphaEarth también se redujo con 95 a 142 puntos; en cualquier caso, una misma comparación puede reportarse como favorable o como nula según cómo se configure la validación cruzada.

La forma de comparar las configuraciones también modificó la interpretación de los resultados. Si la ganancia se hubiera contrastado únicamente con la desviación estándar de cada configuración por separado, se habría mezclado la variabilidad entre sectores con la incertidumbre de la diferencia entre entradas. En este experimento, esa práctica habría podido ocultar una mejora que sí fue visible mediante la comparación pareada. De manera similar, restringir McNemar a la reserva contigua habría dejado solo 26 pares discordantes y poca potencia para detectar diferencias del orden de unas pocas centésimas.

La variación espacial de AlphaEarth también resultó relevante independientemente de la significancia estadística. Su desviación entre pliegues casi duplicó la de la línea base y, en el sector donde obtuvo su peor desempeño, quedó por debajo de ella. Sin embargo, con solo cinco pliegues no fue posible determinar si esta inestabilidad correspondió a un patrón espacial real o a variabilidad de muestreo.

La comparación con Ball et al. (2026) ayudó a delimitar el alcance de los resultados. Aquel estudio utiliza AlphaEarth y TESSERA para distinguir 18 especies forestales en Trentino y encuentra una mejora cercana a 0,05 de macro-F1 que se hace visible con clasificadores no lineales de mayor capacidad. En el presente análisis, que incluyó cuatro clases de cobertura y un Random Forest ajustado, la mejora tuvo una magnitud similar, pero no aumentó al utilizar el perceptrón multicapa. Esta diferencia podría relacionarse con las tareas evaluadas, cuatro clases de cobertura frente a 18 especies forestales, aunque el experimento no permite aislar ese efecto del procedimiento de ajuste del clasificador, que no fue el mismo para el perceptrón.

Cuatro limitaciones delimitaron el alcance de estas cifras. En primer lugar, la referencia provino de WorldCover y fue filtrada a vecindades puras; por tanto, las métricas describen acuerdo con un producto global sobre píxeles relativamente fáciles y no exactitud temática independiente. Además, AlphaEarth se preentrenó con el mapa de cobertura NLCD de Estados Unidos como uno de sus objetivos (Brown et al., 2025), de modo que su representación fue moldeada para reproducir una leyenda de cobertura afín a la de WorldCover, aunque ese producto no participó en el entrenamiento ni NLCD cubre el área de estudio, y parte del acuerdo puede responder a esa afinidad. En segundo lugar, WorldCover no distingue entre manglar intacto y degradado, una diferencia relevante para la CGSM. En tercer lugar, el régimen

principal contó con cinco pliegues y el conservador con tres, por lo que la evidencia estadística depende en buena medida de la prueba de McNemar agrupada, cuyo supuesto de independencia entre puntos solo se cumple aproximadamente. Finalmente, el compuesto húmedo de octubre presentó información para 573 de los 600 puntos y mostró el mayor cambio del índice de agua, lo que pudo introducir ruido adicional en el brazo espectral aunque la mediana de tres meses redujo parcialmente su influencia.

Conclusiones

La comparación controlada mostró que la ventaja de AlphaEarth frente a las variables espectrales dependió tanto del periodo temporal considerado como de la separación espacial entre entrenamiento y validación. Cuando Sentinel-2 pasó de una única fecha a una línea base multitemporal que resumió 2021, la ventaja de AlphaEarth disminuyó respecto a la comparación de una sola fecha. Esta reducción mostró que parte de la ventaja inicial dependía de la configuración de la línea base espectral, cuya cobertura temporal y número de variables aumentaron a la vez, sin que fuera posible aislar la contribución de cada factor.

Bajo el régimen principal de bloques de 6 km, AlphaEarth mantuvo una mejora de 0,038 de macro-F1 frente a la línea base multitemporal, favorable en cuatro de cinco pliegues. Esa ventaja se redujo a centésimas y perdió el respaldo estadístico en dos condiciones: con bloques de 16 km y con los mismos bloques repartidos en diez pliegues, donde el entrenamiento creció y la línea base espectral recuperó la diferencia. Los controles mostraron que el régimen de 16 km original confundía la separación con un entrenamiento reducido y desequilibrado, y que, corregido, la ventaja tampoco aparece a esa separación. Por tanto, el aporte de AlphaEarth no fue una superioridad general: se manifestó a 6 km con el entrenamiento completo y todas las clases representadas, y se redujo tanto con menos entrenamiento como con más y con mayor separación, de modo que la lectura de eficiencia de etiquetas no se sostiene de forma unívoca y la ventaja queda acotada a las condiciones del régimen principal.

El resultado más consistente fue la complementariedad entre las variables espectrales y AlphaEarth. La combinación de ambas fuentes superó a la línea base multitemporal en todos los pliegues del régimen de 6 km y en la malla original de 16 km, y distribuyó la importancia de variables casi por mitades entre las dos fuentes. Estos resultados indicaron que la representación fundacional no contuvo toda la información aportada por las variables espectrales convencionales y que su mayor utilidad, dentro de este experimento, estuvo en complementarlas más que en sustituirlas. Con etiquetas depuradas, esa ventaja se mantuvo a 6 km; en el régimen de 16 km corregido no se mantuvo de forma consistente, de modo que su alcance a mayores distancias de transferencia queda por confirmar con la muestra de referencia de 2025.

Estas conclusiones están condicionadas por la referencia utilizada. Las métricas se calcularon con etiquetas derivadas de WorldCover 2021 y filtradas a píxeles puros, por lo que describen acuerdo con esa referencia y no exactitud temática independiente. En consecuencia, el patrón observado requiere una evaluación posterior con una muestra de referencia propia y con situaciones más difíciles, como píxeles de borde y diferencias entre estados del manglar.

Trabajo futuro

Como continuación del análisis, se plantea comprobar si los patrones observados se mantienen al utilizar una referencia independiente, incorporar una segunda representación fundacional y aumentar la exigencia temporal y espacial de la evaluación. Para ello se propone utilizar una muestra propia de 2025, incorporar TESSERA en un año con cobertura completa, evaluar transferencia temporal entre 2021 y 2025 y volver a examinar la estabilidad espacial de la combinación entre variables espectrales y representaciones fundacionales.

Disponibilidad de datos y código

Los scripts del experimento, el motor de validación espacial, los resultados tabulados y las figuras del informe están disponibles en el repositorio público cgsm-alphaearth-vs-espectral, bajo licencia MIT. Los compuestos mensuales de Sentinel-2 proceden del cubo de datos desarrollado para la tesis; las representaciones de AlphaEarth se obtuvieron de la colección `GOOGLE/SATELLITE_EMBEDDING/V1/ANNUAL` de Google Earth Engine, y las etiquetas de referencia se derivaron de ESA WorldCover 2021, siguiendo los criterios de muestreo descritos en la sección de datos. Los archivos individuales por punto no se incluyen en el repositorio.

Declaración de uso de inteligencia artificial

Durante la elaboración de este informe se utilizó Claude (Anthropic) como herramienta de apoyo en la edición de estilo y depuración de scripts, la revisión de consistencia entre el manuscrito y los resultados tabulados, y la verificación de referencias bibliográficas. El diseño experimental, la ejecución de los análisis, la interpretación de los resultados y la formulación de las conclusiones fueron responsabilidad de la autora. Los datos proceden de las fuentes descritas en el informe y los resultados cuantitativos se obtuvieron mediante la ejecución de los scripts disponibles en el repositorio público.

Bibliografía

Ball, J. G. C., Wicklein, J. A., Feng, Z., Knezevic, J., Jaffer, S., Madhavapeddy, A., Atzberger, C., Dalponte, M. y Coomes, D. A. (2026). Geospatial foundation models enable data-efficient tree species mapping in temperate mountain forests. *Science of Remote Sensing, 14*, Artículo 100466. https://doi.org/10.1016/j.srs.2026.100466

Belgiu, M. y Drăguţ, L. (2016). Random forest in remote sensing: A review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing, 114*, 24-31. https://doi.org/10.1016/j.isprsjprs.2016.01.011

Blanco-Libreros, J. F., López-Rodríguez, S. R., Valencia-Palacios, A. M., Pérez-Vega, G. F. y Álvarez-León, R. (2022). Mangroves from rainy to desert climates: Baseline data to assess future changes and drivers in Colombia. *Frontiers in Forests and Global Change, 5*, Artículo 772271. https://doi.org/10.3389/ffgc.2022.772271

Botero, L. y Salzwedel, H. (1999). Rehabilitation of the Ciénaga Grande de Santa Marta, a mangrove-estuarine system in the Caribbean coast of Colombia. *Ocean & Coastal Management, 42*(2-4), 243-256. https://doi.org/10.1016/S0964-5691(98)00056-8

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5-32. https://doi.org/10.1023/A:1010933404324

Brown, C. F., Brumby, S. P., Guzder-Williams, B., Birch, T., Hyde, S. B., Mazzariello, J., Czerwinski, W., Pasquarella, V. J., Haertel, R., Ilyushchenko, S., Schwehr, K., Weisse, M., Stolle, F., Hanson, C., Guinan, O., Moore, R. y Tait, A. M. (2022). Dynamic World, near real-time global 10 m land use land cover mapping. *Scientific Data, 9*, Artículo 251. https://doi.org/10.1038/s41597-022-01307-4

Brown, C. F., Kazmierski, M. R., Pasquarella, V. J., Rucklidge, W. J., Samsikova, M., Zhang, C., Shelhamer, E., Lahera, E., Wiles, O., Ilyushchenko, S., Gorelick, N., Zhang, L. L., Alj, S., Schechter, E., Askay, S., Guinan, O., Moore, R., Boukouvalas, A. y Kohli, P. (2025). *AlphaEarth Foundations: An embedding field model for accurate and efficient global mapping from sparse label data* [Preimpresión]. arXiv. https://doi.org/10.48550/arXiv.2507.22291

Bunting, P., Rosenqvist, A., Hilarides, L., Lucas, R. M., Thomas, N., Tadono, T., Worthington, T. A., Spalding, M., Murray, N. J. y Rebelo, L.-M. (2022). Global mangrove extent change 1996-2020: Global Mangrove Watch version 3.0. *Remote Sensing, 14*(15), Artículo 3657. https://doi.org/10.3390/rs14153657

Cong, Y., Khanna, S., Meng, C., Liu, P., Rozi, E., He, Y., Burke, M., Lobell, D. B. y Ermon, S. (2022). SatMAE: Pre-training transformers for temporal and multi-spectral satellite imagery. *Advances in Neural Information Processing Systems, 35*.

Donato, D. C., Kauffman, J. B., Murdiyarso, D., Kurnianto, S., Stidham, M. y Kanninen, M. (2011). Mangroves among the most carbon-rich forests in the tropics. *Nature Geoscience, 4*, 293-297. https://doi.org/10.1038/ngeo1123

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., Meygret, A., Spoto, F., Sy, O., Marchese, F. y Bargellini, P. (2012). Sentinel-2: ESA's Optical High-Resolution Mission for GMES Operational Services. *Remote Sensing of Environment, 120*, 25–36. https://doi.org/10.1016/j.rse.2011.11.026

EOX IT Services GmbH. (s. f.). *Sentinel-2 cloudless 2024* [Conjunto de datos]. https://s2maps.eu

Feng, Z., Atzberger, C., Jaffer, S., Knezevic, J., Sormunen, S., Young, R., Lisaius, M. C., Immitzer, M., Jackson, T., Ball, J., Coomes, D. A., Madhavapeddy, A., Blake, A. y Keshav, S. (2026). TESSERA: Temporal embeddings of surface spectra for Earth representation and analysis. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 34818-34831). https://doi.org/10.48550/arXiv.2506.20380

Foody, G. M. (2004). Thematic map comparison: Evaluating the statistical significance of differences in classification accuracy. *Photogrammetric Engineering & Remote Sensing, 70*(5), 627-633. https://doi.org/10.14358/PERS.70.5.627

Foody, G. M. (2020). Explaining the unsuitability of the kappa coefficient in the assessment and comparison of the accuracy of thematic maps obtained by image classification. *Remote Sensing of Environment, 239*, Artículo 111630. https://doi.org/10.1016/j.rse.2019.111630

Giri, C., Ochieng, E., Tieszen, L. L., Zhu, Z., Singh, A., Loveland, T., Masek, J. y Duke, N. (2011). Status and distribution of mangrove forests of the world using earth observation satellite data. *Global Ecology and Biogeography, 20*(1), 154-159. https://doi.org/10.1111/j.1466-8238.2010.00584.x

Gorelick, N., Hancher, M., Dixon, M., Ilyushchenko, S., Thau, D. y Moore, R. (2017). Google Earth Engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment, 202*, 18-27. https://doi.org/10.1016/j.rse.2017.06.031

Gupta, K., Mukhopadhyay, A., Giri, S., Chanda, A., Datta Majumdar, S., Samanta, S., Mitra, D., Samal, R. N., Pattnaik, A. K. y Hazra, S. (2018). An index for discrimination of mangroves from non-mangroves using LANDSAT 8 OLI imagery. *MethodsX, 5*, 1129–1139. https://doi.org/10.1016/j.mex.2018.09.011

INVEMAR. (2024). *Informe técnico final: Monitoreo de las condiciones ambientales y de los cambios estructurales y funcionales en las comunidades vegetales y en los recursos pesqueros de la CGSM*. Instituto de Investigaciones Marinas y Costeras José Benito Vives de Andréis.

Jakubik, J., Roy, S., Phillips, C. E., Fraccaro, P., Godwin, D., Zadrozny, B., Szwarcman, D., Gomes, C., Nyirjesy, G., Edwards, B., Kimura, D., Simumba, N., Chu, L., Mukkavilli, S. K., Lambhate, D., Das, K., Bangalore, R., Oliveira, D., Muszynski, M. y Ramachandran, R. (2023). *Foundation models for generalist geospatial artificial intelligence* [Preimpresión]. arXiv. https://doi.org/10.48550/arXiv.2310.18660

Jaramillo, F., Licero, L., Åhlen, I., Manzoni, S., Rodríguez-Rodríguez, J. A., Guittard, A., Hylin, A., Bolívar, J. C., Jawitz, J. W. y Destouni, G. (2018). Effects of hydroclimatic change and rehabilitation activities on salinity and mangroves in the Ciénaga Grande de Santa Marta, Colombia. *Wetlands, 38*, 755-767. https://doi.org/10.1007/s13157-018-1024-7

McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. *International Journal of Remote Sensing, 17*(7), 1425-1432. https://doi.org/10.1080/01431169608948714

Montes-Chaura, C. C., Latorre-Conde, L., Quintero-Rodríguez, D., Estupiñán-Angarita, B., Rodríguez-Bolaños, J. y Pinto-Lopera, J. E. (2026). Multi-source remote sensing workflow (PlanetScope and Sentinel-1/2) applied to LULCC analysis (2016-2024) in the SDERM-CGSM Ramsar Site, Colombia. *ISPRS Journal of Photogrammetry and Remote Sensing, 241*, 231-252. https://doi.org/10.1016/j.isprsjprs.2026.08.010

Murillo-Sandoval, P. J., Fatoyinbo, L. y Simard, M. (2022). Mangroves cover change trajectories 1984-2020: The gradual decrease of mangroves in Colombia. *Frontiers in Marine Science, 9*, Artículo 892946. https://doi.org/10.3389/fmars.2022.892946

Olofsson, P., Foody, G. M., Herold, M., Stehman, S. V., Woodcock, C. E. y Wulder, M. A. (2014). Good practices for estimating area and assessing accuracy of land change. *Remote Sensing of Environment, 148*, 42-57. https://doi.org/10.1016/j.rse.2014.02.015

Reed, C. J., Gupta, R., Li, S., Brockman, S., Funk, C., Clipp, B., Keutzer, K., Candido, S., Uyttendaele, M. y Darrell, T. (2023). Scale-MAE: A scale-aware masked autoencoder for multiscale geospatial representation learning. En *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 4065-4076). https://doi.org/10.1109/ICCV51070.2023.00378

Rivera-Monroy, V. H., Twilley, R. R., Mancera, J. E., Alcántara-Eguren, A., Castañeda-Moya, E., Casas-Monroy, O., Reyes, F., Restrepo, J., Perdomo, L., Campos, E. y Cotes, G. (2006). Aventuras y desventuras en Macondo: Rehabilitación de la Ciénaga Grande de Santa Marta, Colombia. *Ecotrópicos, 19*(2), 72-93.

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F. y Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913-929. https://doi.org/10.1111/ecog.02881

Rouse, J. W., Haas, R. H., Schell, J. A. y Deering, D. W. (1973). Monitoring vegetation systems in the Great Plains with ERTS. En *Third ERTS Symposium, NASA SP-351* (Vol. 1, pp. 309-317). NASA.

Torres, R., Snoeij, P., Geudtner, D., Bibby, D., Davidson, M., Attema, E., Potin, P., Rommen, B., Floury, N., Brown, M., Traver, I. N., Deghaye, P., Duesmann, B., Rosich, B., Miranda, N., Bruno, C., L'Abbate, M., Croci, R., Pietropaolo, A., Huchler, M. y Rostan, F. (2012). GMES Sentinel-1 mission. *Remote Sensing of Environment, 120*, 9–24. https://doi.org/10.1016/j.rse.2011.05.028

Vinasco, J. S., Rodríguez, D. A., Velásquez, S., Quintero, D. F., Livni, L. R. y Hernández, F. L. (2020). Coverage changes detection at Ciénaga Grande, Santa Marta-Colombia using automatic classification. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences, XLII-3/W12-2020*, 195-200. https://doi.org/10.5194/isprs-archives-XLII-3-W12-2020-195-2020

Xu, H. (2006). Modification of normalised difference water index (NDWI) to enhance open water features in remotely sensed imagery. *International Journal of Remote Sensing, 27*(14), 3025-3033. https://doi.org/10.1080/01431160600589179

Zanaga, D., Van De Kerchove, R., Daems, D., De Keersmaecker, W., Brockmann, C., Kirches, G., Wevers, J., Cartus, O., Santoro, M., Fritz, S., Lesiv, M., Herold, M., Tsendbazar, N.-E., Xu, P., Ramoino, F. y Arino, O.

(2022). *ESA WorldCover 10 m 2021 v200* [Conjunto de datos]. Zenodo. https://doi.org/10.5281/zenodo.7254221